
AssignmentDE

Kiến trúc hệ thống



- Kafka gồm 2 broker và được quản lý bởi zookeeper
- Nifi bao gồm NiFi registry và Nifi được quản lý bởi zookeeper
- HDFS gồm namenode, 2 datanode cùng với nodemanager và resourcemanager phục vụ cho YARN
- Spark gồm 1 master node, 2 worker node và 1 spark-submit
- ▼ Cách thức triển khai, thực hiện các bước
 - Cấu hình các container như trong docker-compose.yml
 - Các dependency cần thiết có trong pom.xml
 - ▼ Set up phần Nifi

Ban đầu chúng ta chưa mount thư mục conf vào Nifi

```
- ./nifi/provenance_repository:/opt/nifi/nifi-current/provenance_repository
- ./nifi/state:/opt/nifi/nifi-current/state
- ./nifi/logs:/opt/nifi/nifi-current/logs
# uncomment the next line after copying the /conf directory from the container to your local directory
#- ./nifi/conf:/opt/nifi/nifi-current/conf
networks:
- persistent_network
```

Sau khi docker compose up thì các thư mục chưa tồn tại sẽ được tạo ra trên local và chúng ta phải tìm ID của container Nifi để copy thư mục conf từ Nifi về local

```
# to get the container ID of NiFi's docker container
> docker ps

# the result will look like this (shortened to fit this article)
CONTAINER ID IMAGE COMMAND
7554d9c68c8f apache/nifi:1.14.0 ...
8af04cd37e06 apache/nifi-registry:1.15.0 ...
a2dacb43ed23 bitnami/zookeeper:3.7.0 ...
# copy the directory from the docker container to the local machine
> docker cp 7554d9c68c8f:/opt/nifi/nifi-current/conf ./nifi/
```

Copy thành công thì lần compose sau chúng ta sẽ bỏ comment câu lệnh

```
- ./nifi/conf:/opt/nifi/nifi-current/conf
```


Chúng ta sẽ mount thư mục các file cấu hình của hdfs ra local

```
■ docker exec -it d4d7897d4c4e9d21fa3279cb0b24f36464d9fcb4fdc6cc3da603b5df0cd3ff3f /bin/sh
sh-4.2$ 1s
LICENSE-binary NOTICE-binary README.txt etc lib licer
LICENSE.txt NOTICE.txt bin include libexec sbin
                                                                               licenses-binary share
sh-4.2$ cd etc
sh-4.2$ ls
hadoop
sh-4.2$ cd hadoop
sh-4.2$ ls
capacity-scheduler.xml
                                   hadoop-user-functions.sh.example kms-site.xml
                                                                                                                    user_ec_policies.xml.template
capacity-scheduler.xml.raw hdfs-rbf-site.xml
configuration.xsl hdfs-site.xml
                                                                                log4j.properties
                                                                                                                    yarn-env.cmd
                                                                               mapred-env.cmd
                                                                              mapred-env.sh yarn-env.sh
mapred-queues.xml.template
mapred-site.xml yarn-site.xml
core-site.xml
core-site.xml.raw
                                   httpfs-env.sh
httpfs-log4j.properties
                                                                                                                    varn-site.xml.raw
                                    httpfs-site.xml
                                                                                                                    yarnservice-log4j.properties
nadoop-env.cmd
hadoop-env.sh kms-acls.xml
hadoop-metrics2.properties kms-env.sh
                                                                                shellprofile.d
ssl-client.xml.example
nadoop-policy.xml
                                    kms-log4j.properties
                                                                                ssl-server.xml.example
sh-4.2$ pwd
sh: p⊡wd: command not found
sh-4.2$ pwd
opt/hadoop/etc/hadoop
 h-4.2$
```

PS C:\Users\Administrator\Desktop\HUST\BigData\Project> docker op d4d7897d4c4e9d21fa3279cb0b24f36464d9fcb4fdc6cc3da603b5df0cd3ff3f:/opt/hadoop/etc/hadoop ./
Successfully copied 120k8 to C:\Users\Administrator\Desktop\HUST\BigData\Project\.\

>	🗀 .idea
>	config
>	hadoop
>	nifi nifi
>	nifi_registry
>	□ src
>	□ target

Copy 2 file core-site.xml và hdfs-site.xml tới ./nifi/conf để phục vụ cho việc truyền file từ Nifi vào HDFS. Copy file danh_sach_sv_de.csv tới ./nifi/conf để phục vụ truyền file sau này.



Đến đây việc chuẩn bị cho Nifi đã hoàn thành.

▼ Producer của Kafka

```
public static void main(String[] args) {
    Properties props = new Properties();
    props.put(ProducerConfig.BODTSTRAP_SERVERS_CONFIG, BODTSTRAP_SERVERS);
    props.put(ProducerConfig.KEY_SERIALIZER_CLASS_CONFIG, "org.apache.kafka.common.serialization.StringSerializer");
    props.put(ProducerConfig.VALUE_SERIALIZER_CLASS_CONFIG, "org.apache.kafka.common.serialization.StringSerializer");

    ObjectMapper objectMapper = new ObjectMapper();


    try (KafkaProducer<String, String> producer = new KafkaProducer<>(props);
        BufferedReader reader = new BufferedReader(new FileReader(logPath))) {
        String line;
        int recordCount = 0;

    while ((line = reader.readLine()) != null) {
            // Process the CSV line and create a JSON string
            String[] fields = line.split(legex ",");
            MapsString, Object> jsonMap = new HashMap<>();
            jsonMap.put( k "student_code", Integer.parseInt(fields[0]));
            jsonMap.put( k "civity", fields[1]);
            jsonMap.put( k "numberOfFile", Integer.parseInt(fields[2]));
            jsonMap.put( k "timestemp", fields[3]);


            String jsonString = objectMapper.writeValueAsString(jsonMap);
            String key = getKey(fields); // Control partitions of records
            ProducerRecord<String, String> record = new ProducerRecord<>(TOPIC_NAME, key, jsonString);
```


Sau khi broker Kafka hoạt động ổn định chạy Producer sẽ đẩy dữ liệu lên Kafka broker

▼ Triển khai phần Nifi để nhận dữ liệu từ kafka, convert record sang parquet và truyền file parquet tới HDFS để lưu trữ ở đường dẫn "/raw_zone/fact/activity".




Cấu hình ConsumeKafka






Cấu hình PutHDFS




• Cấu hình ConvertRecord




OK

Kết quả sau khi thực hiện

Browse Directory




▼ Triển khai Nifi truyền file "danh_sach_sv_de.csv" đến HDFS




Cấu hình PutHDFS như trên.

Cấu hình GetFile



Kết quả sau khi thực hiện



▼ Apache Spark

Chương trình để đọc danh_sach_sv_de.csv chuyển thành dataframe và đọc lần lượt các file parquet để tạo thành dataframe. Từ đó xử lí dữ liệu và xuất output vào HDFS.

```
SparkSession spark = SparkSession.bultder()
.appName("Read Parquet from HDFS and Aggregate Activities")
.config("spark.master", "local")
.getOrCreate();

String studentFilePath = "hdfs://namenode:8020/input/danh_sach_sv_de.csv";

StructType schema = new StructType(new StructField[]{
    DataTypes.createStructField( name: "student_code", DataTypes.IntegerType, nullable: false),
    DataTypes.createStructField( name: "student_name", DataTypes.StringType, nullable: false)
});


Dataset<Row> studentDf = spark.read()
    .format( source: "csv")
    .schema(schema)
    .option("header", "false")
    .load(studentFilePath);

String hdfsPath = "hdfs://namenode:8020/raw_zone/fact/activity";
Dataset<Row> aggregatedDF = df.groupBy( coll: "student_code", ...cols: "activity", "timestamp")
    .agg(sum( columnName: "numberOfFile").as( alias: "totalFile"));

Dataset<Row> outputDF = aggregatedDF.join(studentDf, usingColumn: "student_code")
    .select( col: "timestamp", ...cols: "student_code", "student_name", "activity", "totalFile")
    .orderBy( sortCol: "student_code", ...sortCols: "activity");

String outputHdfsPath = "hdfs://namenode:8020/output/aggregated_activities";
outputDF.write()
    .node( saweMode: "overwrite")
    .option("header", "false")
```

Sau đó chạy lệnh mvn package trong terminal để xuất ra file .jar




Cấu hình spark-submit để khi khởi động sẽ chạy chương trình thực thi quá trình chuyển đổi và đưa ra kết quả

```
spark-submit-job:
image: bitnami/spark:latest
container_name: spark-submit-job
depends_on:
- spark-master
- spark-morker-1
- spark-worker-2
command: bash -c "sleep 30 && spark-submit --class org.spark.ParquetReader --master spark://spark-master:7077 /app/AssignmentDE-1.0-SNAPSHOT.jar"
volumes:
- ./target/AssignmentDE-1.0-SNAPSHOT.jar:/app/AssignmentDE-1.0-SNAPSHOT.jar
networks:
- my_persistent_network
```

Do không phải spark streaming nên phải đợi Nifi truyền hết dữ liệu vào HDFS thì mới khởi động container spark-submit để xử lí.

Kết quả sau khi xử lí được lưu vào HDFS



Copy file .csv vè container

```
docker exec -it 76893e740fa83821571483bb56da8c3259209b1af46384f38cdec63e8688ba94 /bin/sh

sh-4.2$ ls
LICENSE-binary NOTICE-binary README.txt etc lib licenses-binary share
LICENSE.txt NOTICE.txt bin include libexec sbin
sh-4.2$ ls
LICENSE.txt NOTICE.txt bin include libexec sbin
sh-4.2$ ls
LICENSE-binary NOTICE.txt etc libexec sbin
sh-4.2$ ls
LICENSE-binary NOTICE.txt etc libexec sbin
LICENSE-binary NOTICE.txt include licenses-binary share
NOTICE-binary bin lib part-00000-efcbec96-5522-4a0f-852b-65404a81f32b-c000.csv
sh-4.2$
```

Copy file từ container về local

```
PS C:\Users\Administrator\Desktop\VDT\AssignmentDE> docker cp 76893e740fa83821571483bb56da8c3259209b1af46384f38cdec63e8688ba94:opt/hadoop/part-00000-efcbec96-5522-4a0f-852b-65404a8 1f32b-c000.csv ./
Successfully copied 13.8kB to C:\Users\Administrator\Desktop\VDT\AssignmentDE\.\
```

Một số giá trị kết quả

```
6/11/2024,1,Mai Đức An,execute,3
 6<u>0</u>12/2024,1,Mai Đức An,execute,10
6/15/2024,1,Mai Đức An,read,7
6/11/2024,1,Mai Đức An,read,11
6/10/2024,1,Mai Đức An,read,25
6/13/2024,1,Mai Đức An,read,14
6/14/2024,1,Mai Đức An,write,4
6/13/2024,1,Mai Đức An,write,10
6/10/2024,1,Mai Đức An,write,6
6/12/2024,2,Nguyễn Mai Anh,execute,1
6/13/2024,2,Nguyễn Mai Anh,read,3
6/15/2024,2,Nguyễn Mai Anh,write,2
6/11/2024,2,Nguyễn Mai Anh,write,1
6/12/2024,2,Nguyễn Mai Anh,write,19
6/12/2024,3,Ngô Ngọc Tuấn Anh,execute,9
6/10/2024,3,Ngô Ngọc Tuấn Anh,execute,4
6/13/2024,3,Ngô Ngọc Tuấn Anh,execute,9
6/13/2024,3,Ngô Ngọc Tuấn Anh,read,18
6/15/2024,3,Ngô Ngọc Tuấn Anh,read,24
6/13/2024,3,Ngô Ngọc Tuấn Anh,write,3
6/12/2024,3,Ngô Ngọc Tuấn Anh,write,2
6/10/2024,3,Ngô Ngọc Tuấn Anh,write,8
 6/11/2024,4,Trần Trung Anh,execute,7
```

Link source code github:

https://github.com/PJavis/AssignmentDE.git